Predicción del nivel de riesgo cardiometabólico en un conjunto de datos sintético de salud mediante técnicas de clasificación supervisada

Iván David Pertuz · Diego Llanos
Profesor: José Escorcia-Gutierrez
Minería de Datos — Proyecto de aula · Segundo informe de avance (corte 2)
Departamento de Ciencias de la Computación y Electrónica, Universidad de la Costa (CUC), Barranquilla, Colombia
Octubre de 2026

Resumen

Este avance continúa el proyecto de aula sobre el *Dataset Sintético de Salud* (500 registros, 14 variables) y aborda una tarea de clasificación multiclase del nivel de riesgo (Bajo, Medio, Alto) a partir de indicadores clínicos y de estilo de vida. Tras retirar 3 duplicados exactos se trabajó con 497 registros y 11 variables predictoras. El análisis exploratorio mostró que edad, IMC, presión sistólica, colesterol y glucosa aumentan de forma ordenada con el nivel de riesgo, y que la actividad física baja y el tabaquismo se asocian con una mayor proporción de riesgo Alto. Se compararon una regresión logística multinomial, un árbol de decisión y un random forest con una división estratificada 75/25 y validación cruzada de 5 particiones. La regresión logística obtuvo el mejor desempeño (accuracy de 0.856, F1-macro de 0.856 en prueba y F1-macro de 0.844 ± 0.030 en validación cruzada), sin confusiones entre las clases extremas y con la menor brecha entre entrenamiento y prueba. Los resultados son preliminares y se limitan a un conjunto de datos sintético con fines didácticos.

Palabras clave: minería de datos, clasificación supervisada, regresión logística, random forest, riesgo cardiometabólico, matriz de confusión.

1. Introducción

Las enfermedades crónicas no transmisibles, como las cardiovasculares y la diabetes, comparten factores de riesgo medibles en la atención primaria: edad, índice de masa corporal (IMC), glucosa, presión arterial, colesterol, sedentarismo y tabaquismo. Identificar de forma temprana a las personas con un perfil de riesgo elevado permite priorizar el seguimiento y las acciones preventivas. La minería de datos ofrece herramientas para descubrir patrones en estos indicadores y construir modelos que asignen automáticamente un nivel de riesgo a partir de ellos.

El propósito del proyecto es responder la pregunta: *¿es posible clasificar el nivel de riesgo (Bajo, Medio, Alto) de una persona a partir de sus indicadores clínicos y de estilo de vida, y cuáles de esas características se asocian más con la clasificación?* Se trata de una tarea de **clasificación supervisada multiclase** con variable objetivo ordinal. En el primer avance se definió el problema, se revisaron antecedentes y se diagnosticó la estructura y la calidad del conjunto de datos. En este segundo avance se consolida la preparación de los datos, se amplía el análisis exploratorio (EDA) con un enfoque orientado al modelado y se entrenan y evalúan tres clasificadores. Dado que el conjunto de datos es sintético, los resultados ilustran el proceso metodológico y no constituyen criterios clínicos.

2. Estado del arte

El uso de técnicas de minería de datos para analizar factores de riesgo cardiovascular tiene antecedentes en el propio Departamento de Ciencias de la Computación y Electrónica de la Universidad de la Costa. Mendoza Palechor et al. (2017) analizaron la enfermedad cardiovascular combinando técnicas de minería de datos supervisadas y no supervisadas, un enfoque cercano al de este proyecto: clasificar el riesgo y explorar la estructura de los datos con base en variables clínicas.

En un ámbito más amplio de la salud, Ariza-Colpas et al. (2023) aplicaron algoritmos de aprendizaje automático a conjuntos de datos de reconocimiento de actividad humana con fines de atención en salud y compararon el desempeño de distintos clasificadores supervisados. Esto refuerza la necesidad de evaluar varios modelos con métricas complementarias antes de seleccionar uno. Ariza-Colpas et al. (2024) presentaron una revisión analítica del aprendizaje automático aplicado al estudio de los síntomas prolongados de la COVID-19, y mostraron cómo estas técnicas se usan para caracterizar perfiles de pacientes a partir de variables clínicas heterogéneas.

Los profesores del departamento también han trabajado en diagnóstico asistido por inteligencia artificial con imágenes médicas. Mansour et al. (2023) propusieron un modelo basado en inteligencia artificial y analítica de grandes datos para el diagnóstico de hemorragia intracraneal en imágenes de tomografía computarizada. Khan et al. (2024) desarrollaron una red neuronal convolucional acoplada a una red de doble atención para detectar y clasificar leucocitos en imágenes microscópicas de sangre. Aunque estos trabajos usan datos de imagen y aprendizaje profundo, comparten con este proyecto el objetivo de apoyar la identificación temprana de condiciones de salud y la evaluación rigurosa del desempeño mediante métricas por clase.

Desde el punto de vista metodológico, el proyecto se apoya en modelos clásicos de clasificación: la regresión logística, por su interpretabilidad; los árboles de decisión, por generar reglas explícitas; y los bosques aleatorios, que combinan múltiples árboles para reducir la varianza (Breiman, 2001). Todos se implementaron con la biblioteca scikit-learn (Pedregosa et al., 2011). A diferencia de los trabajos con imágenes citados, este proyecto trabaja con datos tabulares de baja dimensión, en los que la interpretabilidad y el análisis de los tipos de error tienen un peso central en la selección del modelo.

3. Metodología

3.1 Fuente, propósito y características del conjunto de datos

Se utilizó el archivo *Dataset_Sintetico_Salud_EDA.xlsx*, proporcionado por el docente en el aula virtual (Moodle) de la asignatura. Según su ficha técnica, contiene 500 registros generados de forma sintética con semilla fija, correspondientes a enero–diciembre de 2025. Su propósito es docente y no corresponde a pacientes reales. Incluye 14 variables: un identificador (*ID_Paciente*), el mes de registro, ocho variables numéricas (edad, IMC, glucosa, presión sistólica, colesterol, horas de sueño, nivel de estrés en escala 1–10 y número de consultas médicas en 12 meses), tres categóricas (género, actividad física y tabaquismo) y la variable objetivo *Nivel_Riesgo*, construida de forma didáctica a partir de varias de las características anteriores.

3.2 Registros, variables y criterios de selección

Tabla 1. Variables y registros antes y después de la preparación

Elemento	Inicial	Final	Decisión
Registros	500	497	Se retiraron 3 duplicados exactos (3 ID repetidos) antes de dividir los datos.
Variables	14	11 predictoras + 1 objetivo	Se excluyeron ID_Paciente y Mes_Registro.
Numéricas	8	8	Edad, IMC, glucosa, presión sistólica, colesterol, sueño, estrés, consultas.
Categóricas	3	3	Género, actividad física, fumador (one-hot).
Objetivo	Nivel_Riesgo	Nivel_Riesgo	Bajo 169 · Medio 196 · Alto 132 (tras retirar duplicados).

ID_Paciente se excluyó por ser un identificador sin significado predictivo. *Mes_Registro* se excluyó porque en el primer avance la proporción mensual de riesgo Alto osciló sin tendencia (entre ≈14 % y ≈42 %), con solo 31–51 registros por mes, y porque no se sigue a las mismas personas en el tiempo. Este es el principal cambio frente al primer avance. Las 11 variables restantes se conservaron porque ningún par presenta una correlación mayor que 0.47 en valor absoluto, de modo que no hay redundancia fuerte.

3.3 Limpieza y preparación

• **Duplicados:** se eliminaron los 3 duplicados exactos antes de la división para evitar fuga de información.

• **Valores faltantes:** IMC (5), glucosa (6), colesterol (3), horas de sueño (7) y actividad física (4), entre 0.6 % y 1.4 % por variable. No se eliminaron filas: se imputaron con la mediana (numéricas) o la moda (categóricas).

• **Valores atípicos:** el criterio IQR identificó posibles atípicos en sueño (9), glucosa (7), presión (6), IMC (4) y consultas (1). Los máximos (glucosa de 336 mg/dL, presión de 226 mmHg) son fisiológicamente posibles y todos los registros más extremos tienen riesgo Alto, por lo que se conservaron.

• **Codificación y escalamiento:** *one-hot encoding* para las categóricas y estandarización (media 0, desviación 1) para las numéricas.

• **Prevención de fugas:** imputación, codificación y escalamiento se encapsularon en un *Pipeline* de scikit-learn, ajustado únicamente con el conjunto de entrenamiento (y con cada partición de entrenamiento en la validación cruzada).

3.4 Técnicas de análisis exploratorio

Se analizaron la distribución de la variable objetivo y de las variables numéricas (histogramas con densidad, media, mediana y asimetría); la comparación de las variables numéricas por nivel de riesgo (diagramas de caja y medianas por clase); la diferencia estandarizada entre las clases Alto y Bajo (d de Cohen); la composición del riesgo según las variables categóricas (barras apiladas al 100 %); y las relaciones entre variables numéricas (matriz de correlación de Pearson y diagramas de dispersión coloreados por clase).

3.5 División de los datos, modelos y estrategia de comparación

Los datos se dividieron en 75 % para entrenamiento (372 registros) y 25 % para prueba (125 registros), de forma estratificada por *Nivel_Riesgo* y con semilla 42. Se entrenaron tres clasificadores con *class_weight = "balanced"* para compensar el leve desbalance: (1) regresión logística multinomial (max_iter = 2000); (2) árbol de decisión (max_depth = 5, min_samples_leaf = 8); y (3) random forest (300 árboles, min_samples_leaf = 3). No se realizó búsqueda de hiperparámetros. La comparación combinó: las métricas en el conjunto de prueba; la validación cruzada estratificada de 5 particiones sobre los 497 registros; la brecha entre entrenamiento y prueba como indicador de sobreajuste; el análisis de los tipos de error en las matrices de confusión; y la interpretabilidad del modelo.

3.6 Métricas de evaluación

Se usaron accuracy, precision, recall y F1-score por clase y en promedio macro (que da el mismo peso a las tres clases), además de la matriz de confusión. Como en un tamizaje de riesgo el error más costoso es no detectar a una persona de riesgo Alto, se reportó por separado el **recall de la clase Alto** y se contabilizaron las confusiones de dos escalones (Bajo ↔ Alto).

3.7 Herramientas

Python con pandas, NumPy, Matplotlib y seaborn para la manipulación y la visualización, y scikit-learn (Pedregosa et al., 2011) para la preparación, el modelado y la evaluación, en un notebook de Jupyter (*Avance2_Proyecto_Pertuz_Llanos.ipynb*) que se ejecuta de principio a fin con semilla fija.

4. Resultados preliminares

4.1 Hallazgos del análisis exploratorio

La Figura 1 muestra que la clase Medio es la más frecuente (39.4 %), seguida de Bajo (34.0 %) y Alto (26.6 %). La razón entre la clase mayoritaria y la minoritaria es de 1.48, un desbalance leve que justificó la estratificación, los pesos balanceados y el uso de métricas macro.

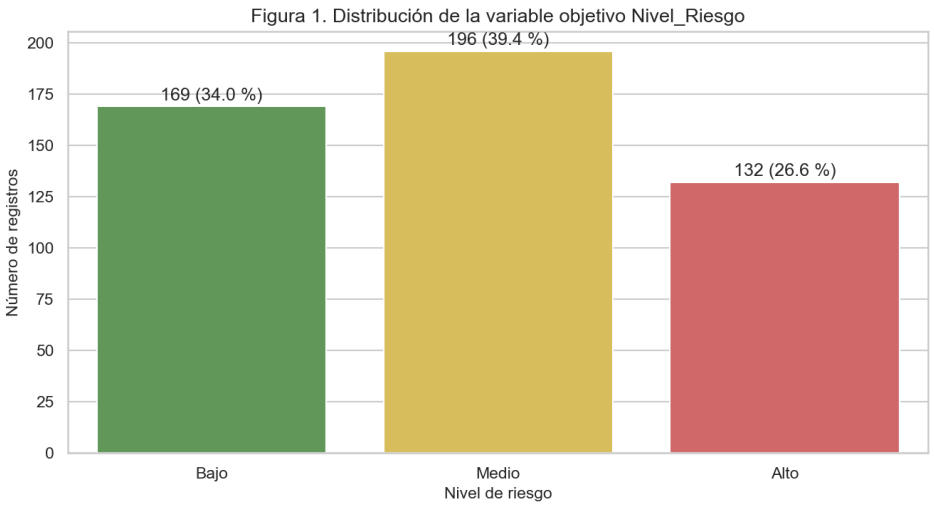


Figura 1. Distribución de la variable objetivo tras retirar duplicados (n = 497).

En la Figura 2, edad, colesterol, sueño y estrés son aproximadamente simétricas, mientras que la glucosa (asimetría de 4.60), la presión sistólica (1.53) y el IMC (1.25) presentan cola derecha por los valores extremos conservados.

Figura 2. Distribución de las variables numéricas (497 registros)

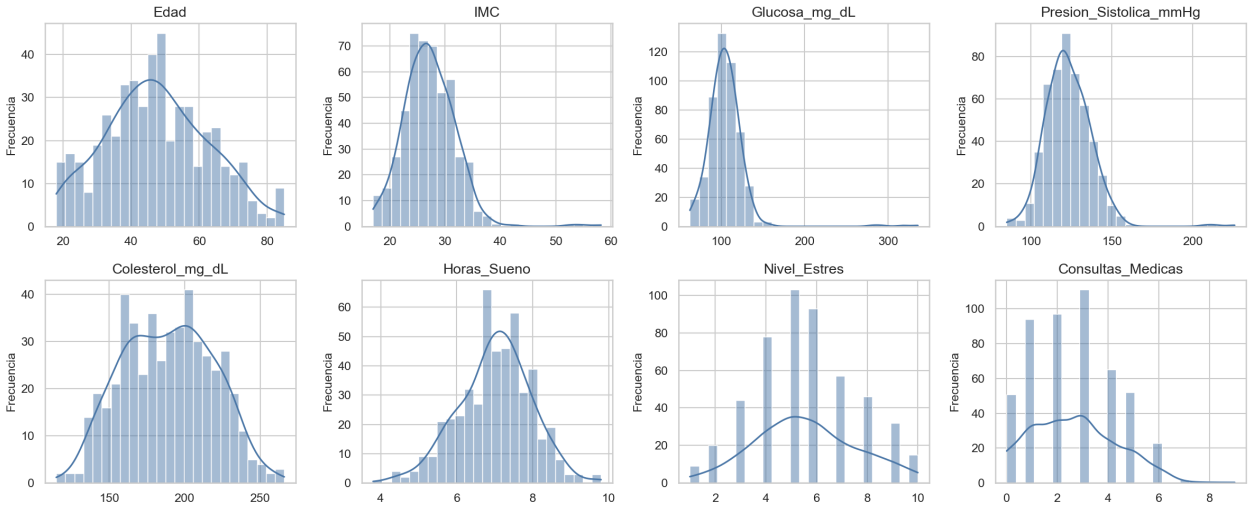


Figura 2. Distribución de las variables numéricas.

La Figura 3 y la Tabla 2 muestran que las medianas de edad, IMC, glucosa, presión y colesterol aumentan de forma ordenada de Bajo a Alto, mientras que el sueño y el estrés cambian poco. Las cajas de clases vecinas se solapan, por lo que ninguna variable separa las clases por sí sola.

Tabla 2. Medianas de las variables numéricas por nivel de riesgo

Nivel	Edad	IMC	Glucosa	Presión	Colesterol	Sueño	Estrés	Consultas
Bajo	37.0	24.3	92.0	117.0	172.0	7.2	5.0	2.0
Medio	49.0	27.4	103.0	122.0	192.0	7.0	6.0	3.0
Alto	59.5	30.6	119.0	133.0	208.5	6.9	6.0	3.0

Nota. Glucosa y colesterol en mg/dL; presión sistólica en mmHg; sueño en horas por noche.

Figura 3. Variables numéricas según el nivel de riesgo

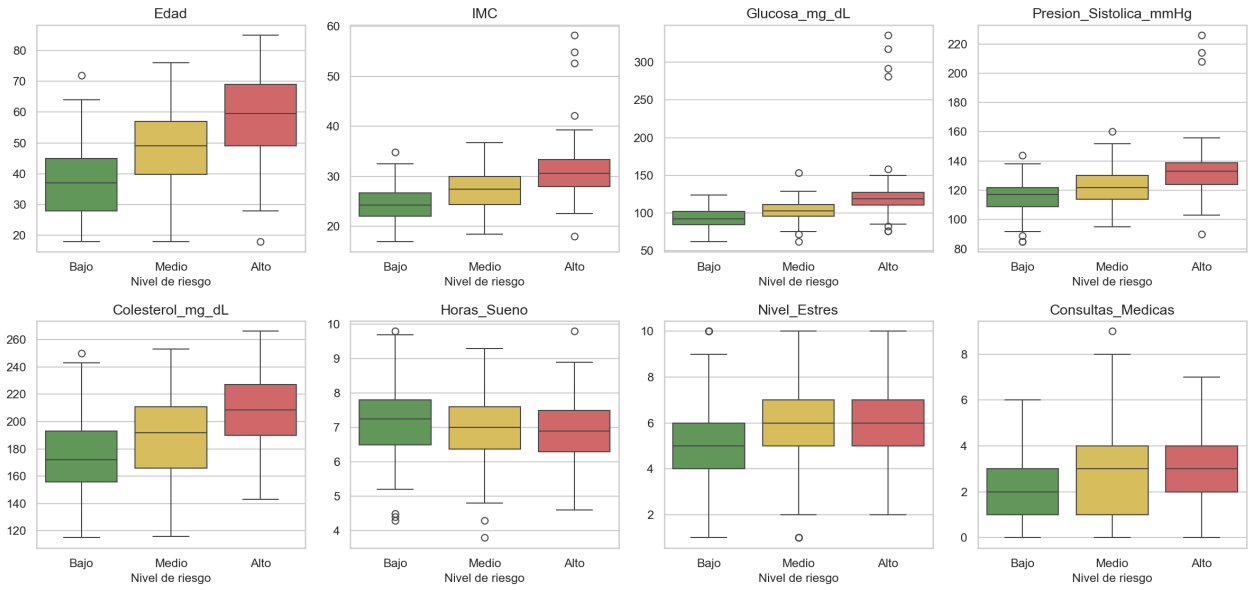


Figura 3. Variables numéricas según el nivel de riesgo.

Según la diferencia estandarizada entre Alto y Bajo (Figura 4), las variables que más separan las clases son edad (1.81 DE), IMC (1.52), colesterol y presión (1.29) y glucosa (1.21). Consultas (0.60), estrés (0.44) y sueño (−0.34) muestran diferencias pequeñas.

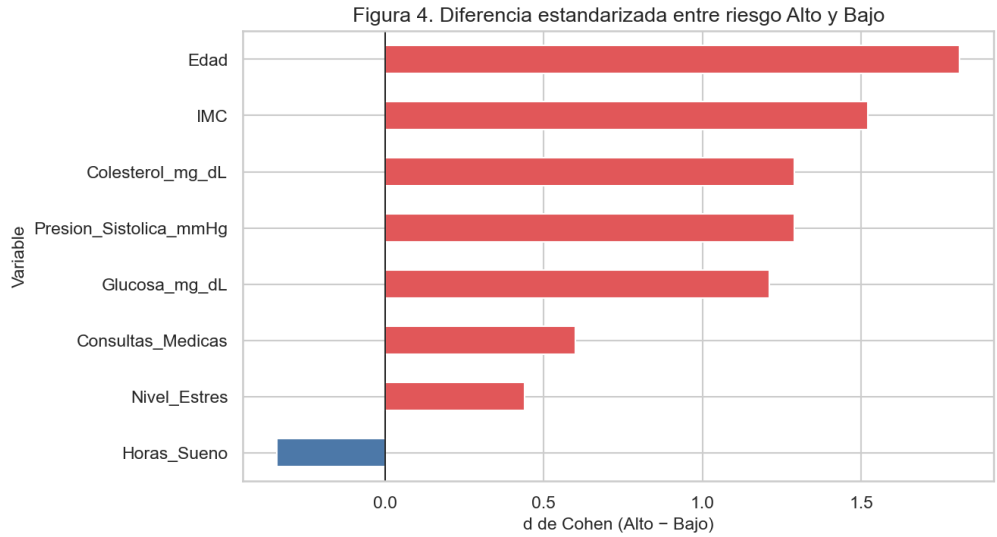


Figura 4. Diferencia estandarizada (d de Cohen) entre las clases Alto y Bajo.

Entre las variables categóricas (Figura 5), la actividad física es la más asociada al riesgo: la proporción de riesgo Alto baja de 42.4 % con actividad baja a 9.3 % con actividad alta. En los fumadores el riesgo Alto es de 37.8 %, frente a 23.3 % en los no fumadores. El género muestra composiciones similares entre Femenino y Masculino, y el grupo Otro/No reporta (n = 12) es demasiado pequeño para interpretarlo.

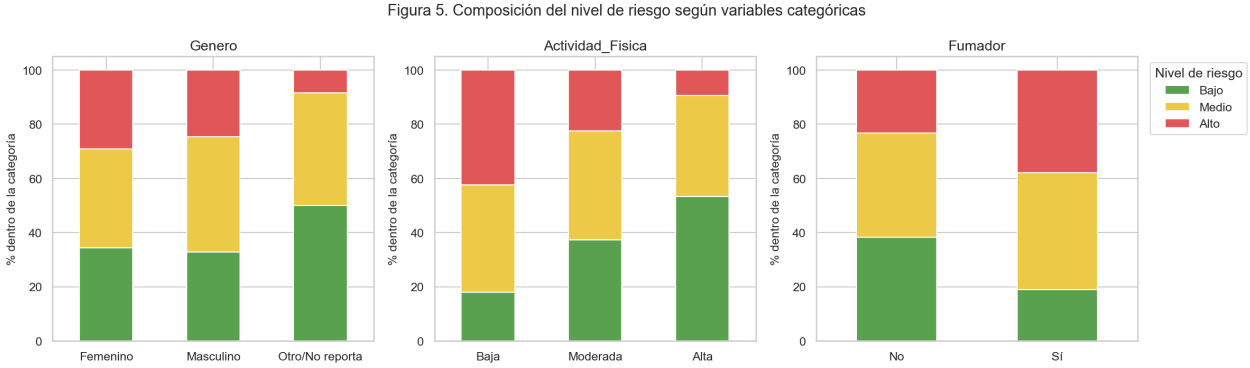


Figura 5. Composición del nivel de riesgo según las variables categóricas (% por fila).

Las correlaciones entre variables numéricas son a lo sumo moderadas (Figura 6): edad–presión (0.465), edad–colesterol (0.405), edad–consultas (0.398) y sueño–estrés (−0.373). En los diagramas de dispersión (Figura 7), los casos de riesgo Alto se concentran en valores altos de edad, presión, IMC y glucosa, con una zona central de mezcla que anticipa errores entre clases vecinas. Todas estas relaciones son asociaciones en datos sintéticos y no permiten afirmar causalidad.

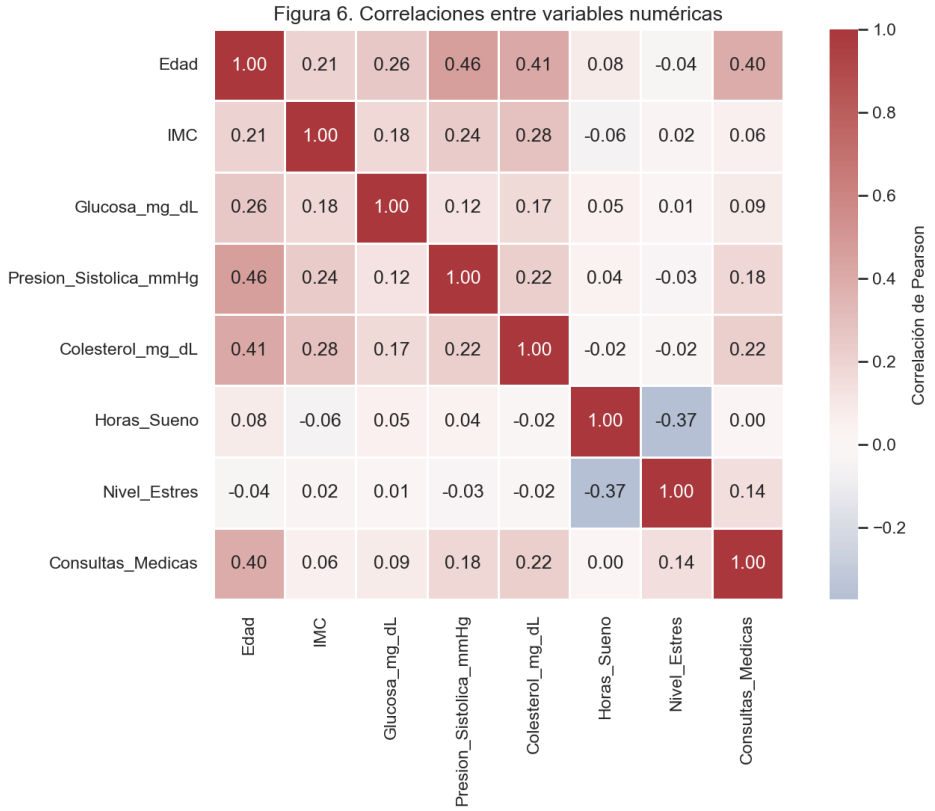


Figura 6. Matriz de correlación de Pearson entre las variables numéricas.

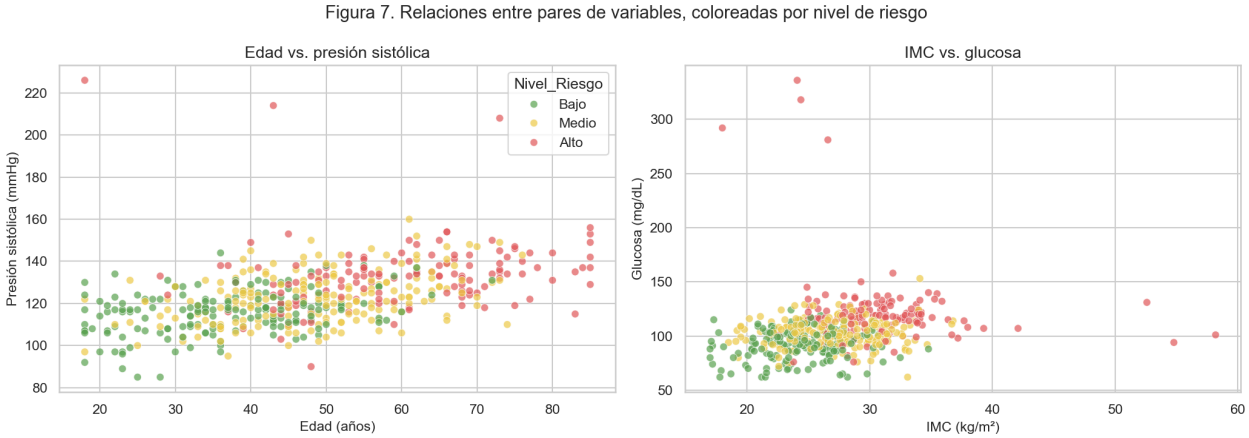


Figura 7. Edad frente a presión sistólica e IMC frente a glucosa, por nivel de riesgo.

4.2 Desempeño de los modelos

La Tabla 3 resume las métricas en el conjunto de prueba (n = 125) y la validación cruzada. La regresión logística obtuvo los mejores valores en accuracy, recall macro y F1-macro, y su validación cruzada (0.844 ± 0.030) es consistente con el resultado en prueba.

Tabla 3. Métricas de los clasificadores en prueba y en validación cruzada (5 particiones)

Modelo	Accuracy	Precision macro	Recall macro	F1 macro	Recall Alto	Accuracy train	F1 macro CV (±DE)
Regresión logística	0.856	0.854	0.858	0.856	0.848	0.871	0.844 ± 0.030
Árbol de decisión	0.648	0.676	0.646	0.656	0.606	0.809	0.627 ± 0.015
Random forest	0.824	0.855	0.822	0.829	0.848	0.984	0.784 ± 0.021

Tabla 4. Métricas por clase en el conjunto de prueba

Modelo	Clase	Precision	Recall	F1	Soporte
Regresión logística	Bajo	0.909	0.930	0.920	43
	Medio	0.830	0.796	0.812	49
	Alto	0.824	0.848	0.836	33
Árbol de decisión	Bajo	0.674	0.721	0.697	43
	Medio	0.556	0.612	0.583	49
	Alto	0.800	0.606	0.690	33
Random forest	Bajo	0.969	0.721	0.827	43
	Medio	0.721	0.898	0.800	49
	Alto	0.875	0.848	0.862	33

4.3 Análisis de las matrices de confusión

La Figura 8 presenta las matrices de confusión y la Tabla 5 resume los tipos de error. La regresión logística acierta en 107 de 125 casos y sus 18 errores son todos entre clases vecinas. No confunde nunca Bajo con Alto y detecta 28 de los 33 casos Alto; los otros 5 los clasifica como Medio. El random forest acierta en 103 casos, tiene el mismo recall de Alto y menos falsas alarmas (4 frente a 6), pero clasifica como Medio a 12 de los 43 casos Bajo. El árbol de decisión acierta solo en 81 casos, deja sin detectar 13 casos Alto y comete un error grave Alto → Bajo.

Figura 8. Matrices de confusión en el conjunto de prueba (n = 125)

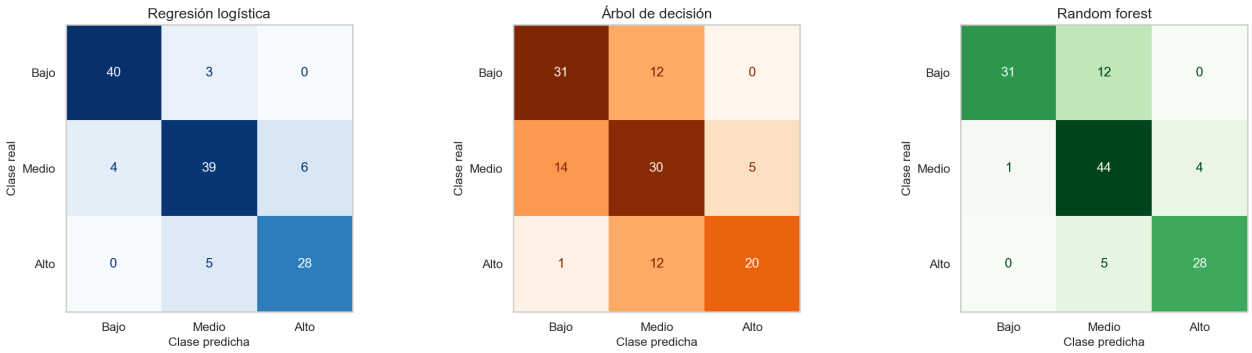


Figura 8. Matrices de confusión en el conjunto de prueba (filas: clase real; columnas: clase predicha).

Tabla 5. Tipos de error en el conjunto de prueba

Modelo	Aciertos	Errores entre clases vecinas	Errores Bajo ↔ Alto	Alto no detectados	Falsas alarmas de Alto
Regresión logística	107	18	0	5	6
Árbol de decisión	81	43	1	13	5
Random forest	103	22	0	5	4

4.4 Comparación e interpretación

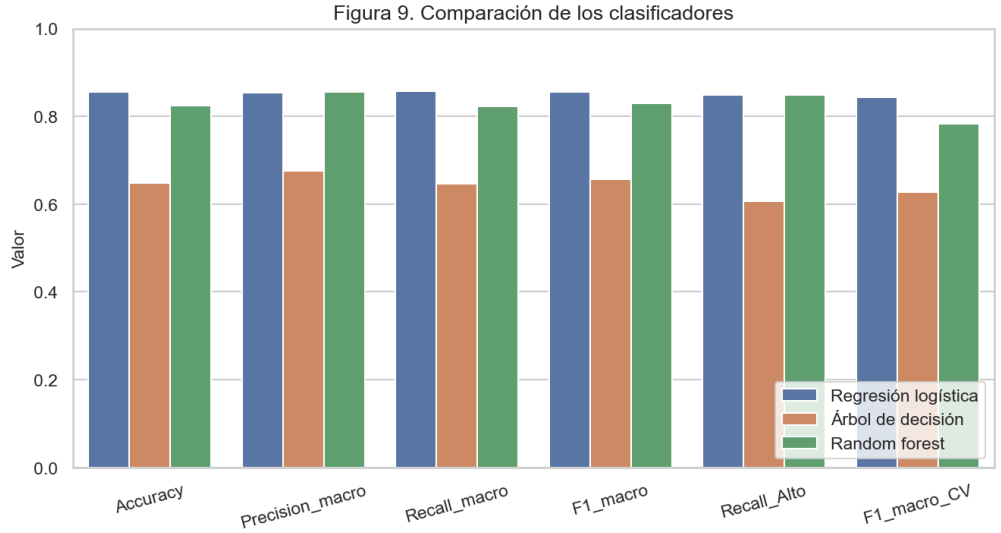


Figura 9. Comparación de las métricas de los tres clasificadores.

La selección no se basó solo en el accuracy (Figura 9). La regresión logística es preferible por cinco evidencias: (1) el mejor F1-macro en prueba (0.856); (2) el mejor F1-macro en validación cruzada (0.844 frente a 0.784 y 0.627); (3) el mayor recall de Alto (0.848, empatado con el random forest) sin errores de dos escalones; (4) la menor brecha entre entrenamiento y prueba (0.015, frente a 0.160 del random forest, cuyo F1 de entrenamiento en validación cruzada es 0.985 y evidencia sobreajuste); y (5) coeficientes interpretables. El random forest queda como alternativa competitiva.

Los coeficientes de la regresión logística para la clase Alto (Figura 10) indican que su probabilidad aumenta con la glucosa (2.435 por desviación estándar), la actividad física baja (1.644), la presión sistólica (1.479), la edad (1.464), el IMC (1.174) y el tabaquismo (1.078). La actividad física alta (−1.392) y más horas de sueño (−0.855) se asocian con menor probabilidad. En el random forest, las variables más importantes son glucosa (0.213), edad (0.181), IMC (0.167) y presión (0.123). La coincidencia entre modelos da solidez a la interpretación, pero no implica causalidad: la etiqueta se construyó a partir de estas mismas variables.

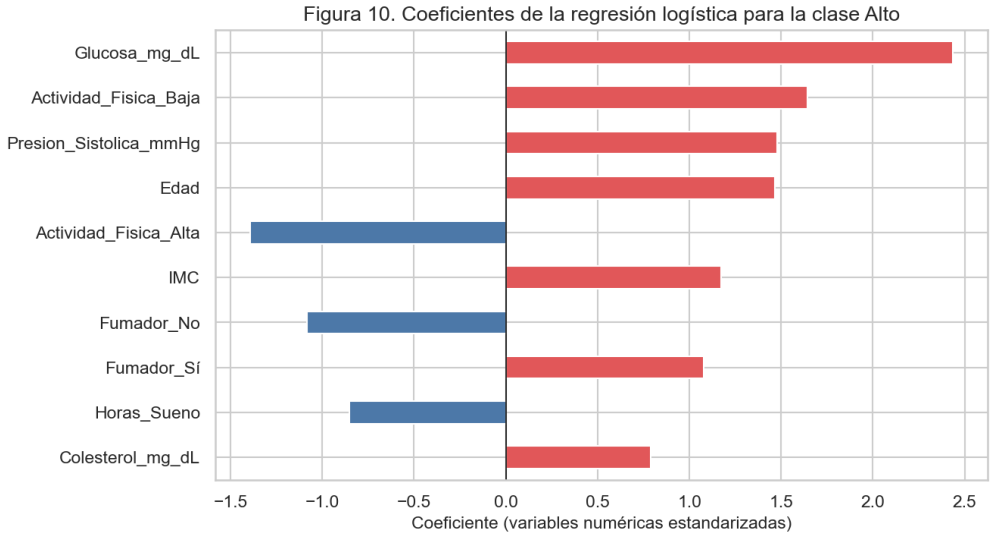


Figura 10. Diez coeficientes de mayor magnitud de la regresión logística para la clase Alto.

4.5 Errores, limitaciones y aspectos pendientes

• La clase Medio es la más difícil de clasificar (F1 de 0.812 en la logística), porque comparte rasgos con las dos clases vecinas. Los 5 casos Alto no detectados por la logística fueron clasificados como Medio.

• El conjunto de datos es sintético y la etiqueta se construyó a partir de las variables predictoras, así que el desempeño mide la recuperación de una regla didáctica y no es extrapolable a la práctica clínica.

• El tamaño muestral es moderado (497 registros) y el grupo de género Otro/No reporta tiene solo 12 personas.

• No se ajustaron hiperparámetros ni el umbral de decisión. El árbol tiene bajo desempeño con la profundidad fijada y el random forest sobreajusta.

• Pendiente para el tercer corte: optimizar hiperparámetros con validación cruzada, ajustar umbrales para priorizar el recall de Alto, evaluar un modelo ordinal y analizar la estabilidad de los coeficientes.

5. Conclusiones preliminares

Los resultados indican que es posible clasificar el nivel de riesgo a partir de los indicadores disponibles con un desempeño alto en este conjunto de datos sintético. La regresión logística multinomial alcanzó un F1-macro de 0.856 en prueba y de 0.844 en validación cruzada, con todos sus errores concentrados en clases vecinas. Las características más asociadas al riesgo Alto fueron la glucosa, la edad, el IMC, la presión sistólica, la actividad física baja y el tabaquismo, mientras que el sueño, el estrés y el número de consultas aportaron poco. El EDA permitió anticipar estos hallazgos y orientar las decisiones de modelado (estratificación, pesos balanceados y conservación de los valores extremos). Estas conclusiones son preliminares y se basan en asociaciones dentro de datos simulados. En el tercer corte se ajustarán los modelos y se completará la discusión para el artículo final.

6. Declaración y evaluación del uso de inteligencia artificial

Se utilizó inteligencia artificial generativa como apoyo en este avance. La Tabla 6 resume cada uso relevante y su evaluación crítica.

Tabla 6. Uso de inteligencia artificial y evaluación crítica

Elemento	Uso 1: notebook, EDA y modelado	Uso 2: estado del arte y referencias	Uso 3: redacción del informe
Herramienta	Claude (Anthropic), modelo Claude Opus 5.5, en la aplicación Claude Code.	Igual que el uso 1, con búsqueda web.	Igual que el uso 1.
Propósito	Construir el notebook reproducible: preparación, EDA, entrenamiento, evaluación e interpretaciones.	Buscar y verificar trabajos de profesores del departamento y sus datos bibliográficos.	Redactar metodología, resultados y conclusiones a partir de las salidas del notebook.
Prompt	«podrias realizar este proyecto incluyendo todas las pautas que piden el nombre de mi compañero diego llanos y ivan pertuz, nombre del profesor José Escorcia-Gutierrez» (adjuntando el PDF de la guía «Avance 2 – proyecto de aula»), seguido del envío de los notebooks *Actividad_EDA_Resuelta.ipynb* y *Actividad_Modelado_Pertuz_Llanos.ipynb* y del archivo *Dataset_Sintetico_Salud_EDA.xlsx*.	Incluido en el prompt del uso 1 («incluyendo todas las pautas»), que exige al menos cinco citas de profesores del departamento.	Incluido en el prompt del uso 1.
Problemas identificados	Advertencias numéricas espurias (RuntimeWarning) de NumPy en macOS que ensuciaban las salidas. Al inicio la herramienta no encontró el dataset y pidió el archivo en lugar de inventar datos.	Un resultado de búsqueda atribuyó el artículo de enfermedad cardiovascular a De la Hoz Manotas como primer autor, pero el primer autor es Mendoza Palechor. Otro describió el artículo de leucocitos como de «gota gruesa», pero el título real menciona imágenes microscópicas de sangre. Un capítulo (detección de infarto agudo de miocardio) no pudo verificarse.	Riesgo de que las cifras del texto no coincidan con el notebook, y de que el texto sustituya el escrito del primer avance.
Ajustes realizados	Se silenciaron solo esas advertencias, con un comentario que lo explica. Se verificó que el notebook se ejecuta completo sin errores y que las cifras de las celdas de texto coinciden con las salidas.	Se corrigieron el orden de autores y la descripción a partir de los metadatos de Crossref y del editor. El capítulo no verificado se excluyó.	Cada cifra del informe se tomó de las salidas del notebook ejecutado. [Grupo: registrar aquí los cambios propios al integrar el texto del primer avance.]
Decisión final	Se conserva el notebook porque usa solo columnas reales del dataset y sus resultados son reproducibles (semilla 42).	Se conservan solo las cinco referencias de profesores verificadas (DOI comprobado), más dos referencias metodológicas.	Se conserva el texto, revisado por el grupo frente al notebook.

Declaración de responsabilidad. Como integrantes del grupo declaramos que revisamos y verificamos el contenido generado con apoyo de herramientas de inteligencia artificial. Consideramos que las partes utilizadas responden a lo solicitado y son coherentes con los datos y resultados obtenidos. Identificamos y corregimos los errores, excesos, omisiones o posibles alucinaciones encontradas. Comprendemos el contenido presentado y asumimos la responsabilidad académica por la totalidad del notebook y del informe entregados.

Iván David Pertuz Diego Llanos

Referencias

Ariza-Colpas, P. P., Piñeres-Melo, M. A., Urina-Triana, M. A., Barceló-Martinez, E., Barceló-Castellanos, C., & Roman, F. (2024). Machine learning applied to the analysis of prolonged COVID symptoms: An analytical review. *Informatics, 11*(3), 48. https://doi.org/10.3390/informatics11030048

Ariza-Colpas, P. P., Vicario, E., Butt Aziz, S., De la Hoz Franco, E., Piñeres-Melo, M. A., Oviedo-Carrascal, A. I., Tariq, M. I., García Restrepo, J. K., & Patara, F. (2023). Machine learning applied to datasets of human activity recognition: Data analysis in health care. *Current Medical Imaging, 19*(1), 46–64. https://doi.org/10.2174/1573405618666220104114814

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Khan, S., Sajjad, M., Abbas, N., Escorcia-Gutierrez, J., Gamarra, M., & Muhammad, K. (2024). Efficient leukocytes detection and classification in microscopic blood images using convolutional neural network coupled with a dual attention network. *Computers in Biology and Medicine, 174*, 108146. https://doi.org/10.1016/j.compbiomed.2024.108146

Mansour, R. F., Escorcia-Gutierrez, J., Gamarra, M., Díaz, V. G., Gupta, D., & Kumar, S. (2023). Artificial intelligence with big data analytics-based brain intracranial hemorrhage e-diagnosis using CT images. *Neural Computing and Applications, 35*(22), 16037–16049. https://doi.org/10.1007/s00521-021-06240-y

Mendoza Palechor, F., De la Hoz Manotas, A., Ariza Colpas, P., Sepulveda Ojeda, J., Morales Ortega, R., & Piñeres Melo, M. (2017). Cardiovascular disease analysis using supervised and unsupervised data mining techniques. *Journal of Software, 12*(2), 81–90. https://doi.org/10.17706/jsw.12.2.81-90

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.